

湘潭大学课程论文

课程名称：机器学习

论文题目：基于Gradient Boosting的分类与回归模型研究及应用分析

所在学院：数学与计算科学学院

专业、班级：2025级数学2班

姓 名：伍可欣

学 号：202521511244

2026年6月

目录

1 绪论	3
1.1 研究背景	3
1.2 国内外研究现状	3
2 Gradient Boosting方法原理	4
2.1 目标函数	4
2.2 模型初始化	5
2.3 梯度下降求解过程	5
2.4 求解结果	6
2.5 算法流程	6
3 分类问题实验：乳腺癌诊断	7
3.1 数据集介绍	7
3.2 问题描述	8
3.3 Gradient Boosting求解过程	9
3.3.1 构建目标函数	9
3.3.2 初始化模型	9
3.3.3 计算负梯度	9
3.3.4 训练回归树拟合伪残差	10
3.3.5 更新模型	10
3.3.6 获得最终分类模型	11
4 回归问题实验：加州房价预测	11
4.1 数据集介绍	11
4.2 数据预处理	12
4.3 Gradient Boosting回归模型构建	12
4.4 模型求解过程	12
4.4.1 初始化模型	12
4.4.2 计算残差	13
4.4.3 训练回归树拟合残差	13
4.4.4 更新模型	14
4.4.5 迭代求解	14
5 数值实验	14
5.1 分类问题实验	14

5.1.1	分类性能分析	14
5.1.2	混淆矩阵分析	15
5.1.3	特征重要性分析	15
5.1.4	预测概率分析	16
5.1.5	对比实验	17
5.1.6	结果总结	19
5.2	回归问题实验	19
5.2.1	数据集基本情况分析	19
5.2.2	回归性能分析	20
5.2.3	特征重要性分析	20
5.2.4	预测结果分析	21
5.2.5	对比实验	22
5.2.6	结果总结	24
6	总结与展望	25
6.1	研究总结	25
6.2	研究展望	26
7	参考文献	26

1 绪论

1.1 研究背景

随着大数据、云计算和人工智能技术的快速发展，各行业积累了海量的数据资源。如何从复杂的数据中挖掘有价值的信息，并利用这些信息进行预测和决策，已经成为机器学习领域的重要研究方向。机器学习算法通过从历史数据中学习数据分布规律，实现对未知样本的预测，在金融风险评估、医疗诊断、工业制造、电子商务推荐以及智能交通等领域得到了广泛应用。

在机器学习任务中，分类（Classification）和回归（Regression）是最常见的两类问题。分类问题旨在预测样本所属的类别，例如垃圾邮件识别、信用违约预测和疾病诊断等；回归问题则用于预测连续数值，例如房价预测、销售额预测以及能源消耗预测等。由于现实数据通常具有非线性、高维度以及复杂特征交互等特点，传统的线性模型往往难以获得较高的预测精度，因此研究高性能的非线性机器学习算法具有重要意义。

集成学习（Ensemble Learning）作为提升模型性能的重要方法，通过构建多个弱学习器并进行组合，能够显著提高模型的泛化能力。其中，Boosting方法由于能够逐步修正模型误差，在实际应用中取得了优异的表现。Gradient Boosting（梯度提升）作为Boosting方法的重要代表，通过不断拟合前一轮模型产生的残差或损失函数的负梯度，实现模型性能的持续优化。由于其具有较高的预测精度和良好的泛化能力，Gradient Boosting已经成为解决分类与回归问题的重要工具，并进一步催生了XGBoost、LightGBM和CatBoost等高性能算法。

因此，研究Gradient Boosting算法的基本原理、实现过程以及在分类和回归任务中的应用，对于理解现代集成学习方法和提升数据分析能力具有重要的理论意义和实际价值。

1.2 国内外研究现状

Boosting思想最早由Schapire（1990）提出，其核心思想是将多个弱学习器组合成一个强学习器，从而提高整体预测性能。随后，Freund和Schapire于1997年提出AdaBoost（Adaptive Boosting）算法，该算法通过动态调整样本权重来关注难分类样本，成为Boosting领域的重要里程碑。

在此基础上，Friedman（2001）提出Gradient Boosting Machine（GBM）算法，将梯度下降思想引入Boosting框架中。该方法不再局限于特定损失函数，而是通过拟合损失函数的负梯度实现模型优化，从而能够统一处理分类和回归问题。Gradient Boosting的提出极大推动了集成学习的发展，并成为后续研究的重要基础。

随着数据规模不断增长，传统GBDT在训练速度和资源消耗方面逐渐暴露出不足。为了解决这些问题，Chen和Guestrin（2016）提出XGBoost算法。该算法通过引入正则化项、二阶梯度信息以及并行计算机制，显著提高了模型的预测性能和训练效率，并在多个机器学习竞赛中取得优异成绩。

随后，Microsoft研究团队于2017年提出LightGBM算法，通过基于直方图（Histogram）的特征离散化技术以及Leaf-wise树生长策略，大幅提升了训练速度和内存利用率，使Gradient Boosting能够应用于更大规模的数据集。

同年，Yandex研究团队提出CatBoost算法。该算法针对类别型特征处理过程中容易出现的目标泄露问题进行了优化，并通过有序提升（Ordered Boosting）机制提高模型稳定性，在包含大量类别变量的数据集上表现出较强竞争力。

近年来，国内外学者广泛将Gradient Boosting及其改进算法应用于金融风险控制、医疗健康分析、工业故障诊断、能源预测以及电子商务推荐等领域。大量研究结果表明，与传统决策树、支持向量机以及神经网络等方法相比，Gradient Boosting在结构化数据建模任务中通常能够获得更高的预测精度和更好的泛化性能。因此，深入研究Gradient Boosting算法及其应用具有重要的研究价值和实践意义。

2 Gradient Boosting方法原理

Gradient Boosting（梯度提升）是一种基于Boosting思想的集成学习方法，其核心思想是在函数空间中采用梯度下降（Gradient Descent）策略，通过逐步训练多个弱学习器来逼近目标函数。每一个新的弱学习器都用于拟合当前模型的残差（Residual）或损失函数的负梯度方向，从而不断降低预测误差。

2.1 目标函数

给定训练数据集

$$D = (x_i, y_i)_{i=1}^N \quad (2.1)$$

其中：

- x_i 表示输入特征；
- y_i 表示目标变量；
- N 表示样本数量。

Gradient Boosting的目标是寻找一个函数 $F(x)$ ，使其最小化经验风险：

$$\mathcal{L}(F) = \sum_{i=1}^N L(y_i, F(x_i)) \quad (2.2)$$

其中：

- $L(\cdot)$ 表示损失函数；
- $F(x_i)$ 表示模型预测值。

对于回归问题，通常采用平方误差损失函数：

$$\frac{1}{2} (y_i - F(x_i))^2 \quad (2.3)$$

此时目标函数可写为：

$$\sum_{i=1}^N \frac{1}{2} (y_i - F(x_i))^2 \quad (2.4)$$

2.2 模型初始化

首先构建一个初始模型：

$$\arg \min_{\gamma} \sum_{i=1}^N L(y_i, \gamma) \quad (2.5)$$

对于平方损失函数，上式可简化为：

$$\frac{1}{N} \sum_{i=1}^N y_i \quad (2.6)$$

即采用训练样本标签的均值作为初始预测值。

2.3 梯度下降求解过程

在第 m 次迭代时，计算损失函数关于当前模型预测值的负梯度：

$$\left[\frac{\partial L(y_i, F(x_i))}{\partial F(x_i)} \right]_{F(x)=F_{m-1}(x)} \quad (2.7)$$

其中 r_{im} 称为伪残差（Pseudo Residual）。

对于平方损失函数：

$$\frac{1}{2} (y_i - F(x_i))^2 \quad (2.8)$$

其梯度为：

$$-(y_i - F(x_i)) \quad (2.9)$$

因此负梯度可表示为：

$$y_i - F_{m-1}(x_i) \quad (2.10)$$

即真实值与预测值之间的残差。

随后训练一个新的弱学习器（通常为回归树）：

$$h_m(x) \quad (2.11)$$

用于拟合伪残差：

$$h_m(x) \approx r_{im} \quad (2.12)$$

然后求解最佳步长：

$$\arg \min_{\gamma} \sum_{i=1}^N L(y_i, F_{m-1}(x_i) + \gamma h_m(x_i)) \quad (2.13)$$

最后更新模型：

$$F_{m-1}(x) + \eta \gamma_m h_m(x) \quad (2.14)$$

其中：

- η 为学习率（Learning Rate）；
- γ_m 为当前弱学习器的最优权重。

2.4 求解结果

经过 M 轮迭代后，最终模型可表示为：

$$F_0(x) + \sum_{m=1}^M \eta \gamma_m h_m(x) \quad (2.15)$$

可以看出，Gradient Boosting最终得到的是多个弱学习器的加法模型（Additive Model）。每个新加入的学习器都用于修正前一轮模型的预测误差，从而不断降低损失函数值，提高模型预测精度。

2.5 算法流程

Gradient Boosting算法的主要步骤如下：

1. 初始化模型 $F_0(x)$ ；
2. 计算当前模型的负梯度（伪残差）；
3. 训练新的回归树拟合伪残差；
4. 求解最优步长 γ_m ；

5. 更新模型：

$$F_m(x) = F_{m-1}(x) + \eta \gamma_m h_m(x)$$

6. 重复步骤2至步骤5，直到达到预设迭代次数；

7. 输出最终模型 $F_M(x)$ 。

通过不断沿损失函数的负梯度方向进行优化，Gradient Boosting能够有效提升模型性能，并广泛应用于分类与回归任务中。

3 分类问题实验：乳腺癌诊断

3.1 数据集介绍

为了验证Gradient Boosting算法在分类任务中的应用效果，本文选取Breast Cancer Wisconsin (Diagnostic) 数据集进行实验研究。该数据集来源于UCI Machine Learning Repository，其下载地址如下：

<https://archive.ics.uci.edu/dataset/17/breast+cancer+wisconsin+diagnostic>

该数据集包含569个样本，其中恶性肿瘤（Malignant）样本212个，良性肿瘤（Benign）样本357个。每个样本包含30个连续型特征，这些特征由乳腺细胞核图像提取获得，主要反映细胞核的形状、大小以及纹理等信息，例如：

- Radius（半径）
- Texture（纹理）
- Perimeter（周长）
- Area（面积）
- Smoothness（平滑度）
- Compactness（紧凑度）
- Concavity（凹陷程度）

设数据集表示为：

$$D = (x_i, y_i)_{i=1}^N \tag{3.1}$$

其中：

- $x_i \in \mathbb{R}^{30}$ 表示第*i*个样本的特征向量；
- y_i 表示对应类别标签；
- $N = 569$ 表示样本总数。

类别标签定义为：

$$y_i = \begin{cases} 1, & \text{恶性肿瘤} \\ 0, & \text{良性肿瘤} \end{cases} \quad (3.2)$$

本实验的目标是根据患者肿瘤特征预测其属于良性还是恶性肿瘤，因此属于典型的二分类问题。

3.2 问题描述

对于给定样本特征向量 x ，希望建立分类函数：

$$F(x) \quad (3.3)$$

使其能够准确预测样本所属类别。Gradient Boosting通过不断构建新的决策树来修正已有模型的预测误差，从而逐步提高分类性能。

对于二分类问题，模型输出首先表示为一个实数值：

$$F(x) \quad (3.4)$$

随后利用Sigmoid函数将其转换为类别概率：

$$p(x) = \frac{1}{1 + \exp[-F(x)]} \quad (3.5)$$

其中：

$$p(x) = P(y = 1|x) \quad (3.6)$$

表示样本属于恶性肿瘤的概率。

最终分类结果定义为：

$$\hat{y} = \begin{cases} 1, & p(x) \geq 0.5 \\ 0, & p(x) < 0.5 \end{cases} \quad (3.7)$$

3.3 Gradient Boosting求解过程

3.3.1 构建目标函数

对于二分类问题，Gradient Boosting通常采用对数损失函数（Logistic Loss）作为优化目标：

$$L(y_i, F(x_i)) = -y_i \log p_i - (1 - y_i) \log(1 - p_i) \quad (3.8)$$

其中：

$$p_i = \frac{1}{1 + \exp[-F(x_i)]} \quad (3.9)$$

整个训练集上的目标函数可表示为：

$$\mathcal{L}(F) = \sum_{i=1}^N L(y_i, F(x_i)) \quad (3.10)$$

Gradient Boosting的目标是寻找函数 $F(x)$ ，使目标函数达到最小值。

3.3.2 初始化模型

首先构建初始模型：

$$F_0(x) = \log \left(\frac{\bar{y}}{1 - \bar{y}} \right) \quad (3.11)$$

其中：

$$\bar{y} = \frac{1}{N} \sum_{i=1}^N y_i \quad (3.12)$$

表示训练集中恶性肿瘤样本所占比例，此时所有样本均采用相同的初始预测值。

3.3.3 计算负梯度

在第 m 轮迭代中，根据当前模型计算预测概率：

$$p_i = \frac{1}{1 + \exp[-F_{m-1}(x_i)]} \quad (3.13)$$

然后计算目标函数关于模型输出的负梯度：

$$r_{im} = \frac{\partial L(y_i, F(x_i))}{\partial F(x_i)} \quad (3.14)$$

对于Logistic Loss，上式可化简为：

$$r_{im} = y_i - p_i \quad (3.15)$$

其中 r_{im} 称为伪残差（Pseudo Residual），伪残差反映了当前模型预测结果与真实标签之间的误差。

3.3.4 训练回归树拟合伪残差

利用训练样本及其对应伪残差：

$$(x_i, r_{im})_{i=1}^N \quad (3.16)$$

训练一棵新的回归树：

$$h_m(x) \quad (3.17)$$

使其尽可能拟合当前伪残差：

$$h_m(x_i) \approx r_{im} \quad (3.18)$$

由于每棵树学习的都是前一轮模型尚未解释的误差，因此模型能够不断提高分类能力。

3.3.5 更新模型

将新训练得到的回归树加入已有模型：

$$F_m(x) = F_{m-1}(x) + \eta h_m(x) \quad (3.19)$$

其中：

- η 为学习率；
- $h_m(x)$ 为第 m 棵回归树。

学习率用于控制模型更新幅度，以提高模型的泛化能力。

3.3.6 获得最终分类模型

重复执行伪残差计算、回归树训练以及模型更新过程，共进行 M 轮迭代。最终得到Gradient Boosting分类模型：

$$F_M(x) = F_0(x) + \sum_{m=1}^M \eta h_m(x) \quad (3.20)$$

对于任意测试样本 x ，其属于恶性肿瘤的预测概率为：

$$P(y = 1|x) = \frac{1}{1 + \exp[-F_M(x)]} \quad (3.21)$$

根据预测概率即可完成乳腺癌良恶性的分类预测。

4 回归问题实验：加州房价预测

4.1 数据集介绍

为了验证Gradient Boosting算法在回归任务中的应用效果，本文选取California Housing数据集进行实验。该数据集可通过Scikit-Learn官方接口获取，数据集说明地址如下：

```
https://scikit-learn.org/stable/modules/generated/sklearn.datasets.  
fetch_california_housing.html
```

California Housing数据集来源于美国加利福尼亚州不同地区的住房统计信息，共包含20640个样本。每个样本由8个数值型特征组成，主要包括住户收入中位数、房屋年龄、平均房间数、平均卧室数、人口数量、平均入住人数、纬度和经度等变量。

设数据集表示为：

$$D = \{(x_i, y_i)\}_{i=1}^N \quad (4.1)$$

其中：

- $x_i = (x_{i1}, x_{i2}, \dots, x_{i8})$ 表示第 i 个地区的特征向量；
- y_i 表示第 i 个地区的房屋价格中位数；
- $N = 20640$ 表示样本总数。

由于目标变量 y_i 为连续数值，因此该实验属于典型的回归问题。实验目标是根据地区住房相关特征预测该地区的房屋价格中位数。

4.2 数据预处理

为了评估模型在未知数据上的预测能力，将原始数据集划分为训练集和测试集：

$$D = D_{train} \cup D_{test} \quad (4.2)$$

其中训练集占总数据集的80%，测试集占20%。训练集用于模型学习，测试集用于评价模型预测性能。

4.3 Gradient Boosting回归模型构建

对于回归问题，Gradient Boosting通过构建多个回归树来逐步逼近真实目标值。其最终模型可表示为多个弱学习器的加法形式：

$$F_M(x) = F_0(x) + \sum_{m=1}^M \eta h_m(x) \quad (4.3)$$

其中：

- $F_M(x)$ 表示最终预测模型；
- $F_0(x)$ 表示初始模型；
- $h_m(x)$ 表示第 m 棵回归树；
- M 表示回归树的数量；
- η 表示学习率。

4.4 模型求解过程

4.4.1 初始化模型

在回归任务中，通常采用平方误差损失函数作为优化目标：

$$L(y_i, F(x_i)) = \frac{1}{2} (y_i - F(x_i))^2 \quad (4.4)$$

整体目标函数为：

$$\mathcal{L}(F) = \sum_{i=1}^N \frac{1}{2} (y_i - F(x_i))^2 \quad (4.5)$$

首先使用训练集中目标变量的均值作为初始预测值：

$$F_0(x) = \frac{1}{N} \sum_{i=1}^N y_i \quad (4.6)$$

该初始模型为所有样本提供相同的预测值。

4.4.2 计算残差

在第 m 次迭代时，根据上一轮模型 $F_{m-1}(x)$ 的预测结果计算残差：

$$r_{im} = y_i - F_{m-1}(x_i) \quad (4.7)$$

其中：

- r_{im} 表示第 m 次迭代时第 i 个样本的残差；
- y_i 表示真实房价；
- $F_{m-1}(x_i)$ 表示上一轮模型的预测房价。

对于平方误差损失函数，其负梯度为：

$$-\frac{\partial L(y_i, F(x_i))}{\partial F(x_i)} = y_i - F(x_i) \quad (4.8)$$

因此，在平方损失下，残差正好等于损失函数的负梯度方向。

4.4.3 训练回归树拟合残差

利用样本特征和残差构造新的训练集：

$$\{(x_i, r_{im})\}_{i=1}^N \quad (4.9)$$

训练一棵回归树：

$$h_m(x) \quad (4.10)$$

使其尽可能拟合当前残差：

$$h_m(x_i) \approx r_{im} \quad (4.11)$$

该过程表示第 m 棵树主要学习上一轮模型尚未解释的误差信息。

4.4.4 更新模型

将新训练得到的回归树加入已有模型：

$$F_m(x) = F_{m-1}(x) + \eta h_m(x) \quad (4.12)$$

其中， η 为学习率，用于控制每一轮模型更新的幅度。较小的学习率可以降低过拟合风险，但通常需要更多的迭代次数。

4.4.5 迭代求解

重复执行残差计算、回归树训练和模型更新过程，共进行 M 轮迭代。最终得到 Gradient Boosting 回归模型：

$$F_M(x) = F_0(x) + \sum_{m=1}^M \eta h_m(x) \quad (4.13)$$

对于任意测试样本 x ，模型输出：

$$\hat{y} = F_M(x) \quad (4.14)$$

其中 $\hat{y}$ 表示预测的房屋价格中位数。通过不断拟合残差，Gradient Boosting 能够逐步减小预测误差，从而提高房价预测精度。

5 数值实验

5.1 分类问题实验

采用 Gradient Boosting 算法对 Breast Cancer Wisconsin 数据集进行分类实验。数据集共包含 569 个样本和 30 个特征变量，经过标签转换后，其中良性肿瘤样本 357 个，恶性肿瘤样本 212 个。实验过程中未发现缺失值，因此无需进行缺失值填补处理。按照 80% 和 20% 的比例划分训练集和测试集，最终得到 455 个训练样本和 114 个测试样本。

5.1.1 分类性能分析

Gradient Boosting 模型在测试集上的分类性能如表 1 所示。

Table 1: Gradient Boosting分类结果

评价指标	结果
Accuracy	0.9649
Precision	1.0000
Recall	0.9048
F1-score	0.9500

从表1可以看出，Gradient Boosting模型取得了96.49%的分类准确率，说明模型能够正确识别绝大多数测试样本;模型精确率达到100%，表明所有被预测为恶性肿瘤的样本均为真实恶性样本，即不存在良性肿瘤被误诊为恶性肿瘤的情况;模型召回率为90.48%，说明模型成功识别了90.48%的恶性肿瘤样本，但仍存在少量恶性样本被漏检。综合考虑精确率和召回率后，模型的F1-score达到95.00%，表明模型具有较好的综合分类能力。

5.1.2 混淆矩阵分析

为了进一步分析模型分类情况，统计得到测试集混淆矩阵，如表2所示。

Table 2: 混淆矩阵

	预测良性	预测恶性
真实良性	72	0
真实恶性	4	38

表2反映了在本次分类实验中，72个良性样本被正确分类；38个恶性样本被正确分类；4个恶性样本被误判为良性；没有良性样本被误判为恶性。

从医学诊断角度来看，模型不存在误诊情况，即不会将健康患者错误判断为恶性肿瘤患者。但仍有4例恶性肿瘤样本被漏诊，这说明模型在恶性样本识别方面仍有进一步提升空间。

5.1.3 特征重要性分析

Gradient Boosting能够自动评估各特征对分类结果的重要程度。实验得到的重要特征排序如表3所示。

Table 3: 前10个重要特征	
特征名称	Importance
Worst Perimeter	0.5295
Mean Concave Points	0.1548
Worst Concave Points	0.0812
Worst Radius	0.0544
Mean Texture	0.0314
Worst Texture	0.0293
Worst Area	0.0252
Worst Concavity	0.0189
Mean Area	0.0151
Area Error	0.0141

由表3可知，Worst Perimeter的重要性最高，达到0.5295，占总重要性的50%以上，说明肿瘤细胞核最大周长对分类结果具有决定性影响。此外，Mean Concave Points和Worst Concave Points的重要性也较高，表明细胞核边缘凹陷程度与肿瘤恶性程度密切相关。这些结果与临床医学中关于恶性肿瘤细胞形态学特征的研究结论基本一致。

5.1.4 预测概率分析

为了观察模型预测置信度，随机选取部分测试样本预测结果，如表4所示。

Table 4: 部分样本预测结果		
真实标签	预测标签	恶性概率
0	0	0.000521
1	1	0.999557
0	0	0.220210
1	1	0.946222
0	0	0.018279
0	0	0.000634
1	1	0.824667
0	0	0.003050
0	0	0.000429
0	0	0.000524

从表4可以发现，大部分样本的预测概率接近0或1。例如，恶性样本的预测概率达到0.999557，而良性样本的预测概率仅为0.000521。这说明模型对于绝大多数样本具有较高的分类置信度。同时，部分样本预测概率接近分类边界，例如概率为0.220210的样本，这类样本通常位于良恶性类别交界区域，分类难度较高，也是模型产生误判的主要来源。

5.1.5 对比实验

为了进一步验证Gradient Boosting算法的分类性能，本文选取Logistic Regression（逻辑回归）作为对比模型，在相同的数据集、训练集与测试集划分条件下进行实验。两种模型的性能对比如表5所示。

Table 5: Gradient Boosting与Logistic Regression性能对比

模型	Accuracy	Precision	Recall
Gradient Boosting	0.9649	1.0000	0.9048
Logistic Regression	0.9649	0.9750	0.9286

由表5可以看出，两种模型均取得了96.49%的分类准确率，说明二者都能够有效完成乳腺癌良恶性分类任务。从整体分类效果来看，两种模型性能较为接近。

然而进一步分析Precision和Recall指标可以发现，两种模型在分类策略上存在明显差异。

Gradient Boosting模型的Precision达到100%，说明所有被预测为恶性肿瘤的样本均为真实恶性样本，即不存在良性样本被误判为恶性的情况。相比之下，Logistic Regression的Precision为97.50%，略低于Gradient Boosting。

在Recall指标方面，Logistic Regression取得了92.86%的召回率，高于Gradient Boosting的90.48%。这表明Logistic Regression能够识别出更多真实恶性肿瘤样本，而Gradient Boosting存在更多漏诊情况。

混淆矩阵分析

为了进一步分析两种模型的分类结果，统计得到的混淆矩阵如表6和表7所示。

Table 6: Gradient Boosting混淆矩阵

	预测良性	预测恶性
真实良性	72	0
真实恶性	4	38

Table 7: Logistic Regression混淆矩阵

	预测良性	预测恶性
真实良性	71	1
真实恶性	3	39

由表6可知，Gradient Boosting正确识别了72个良性样本和38个恶性样本，同时漏诊了4个恶性样本，但没有出现误诊情况。

由表7可知，Logistic Regression正确识别了71个良性样本和39个恶性样本，漏诊3个恶性样本，同时将1个良性样本误判为恶性样本。

因此可以发现：Gradient Boosting更加保守，仅在高度确信时才将样本判定为恶性，因此误诊率更低；Logistic Regression更加倾向于识别恶性样本，因此能够降低漏诊率，但会带来少量误诊。

Precision曲线分析

为了比较两种模型在测试集上的分类稳定性，绘制了累计Precision变化曲线，如图1所示。




Figure 1: Precision对比曲线

从图1可以看出，Gradient Boosting的Precision曲线几乎始终保持在1附近，说明模型在整个测试过程中几乎没有产生假阳性（False Positive），具有较高的分类可信度。

相比之下，Logistic Regression在测试初期波动较大，随着测试样本数量增加，Precision逐渐趋于稳定，最终稳定在0.975左右。虽然略低于Gradient Boosting，但整体仍保持较高水平。

这说明Gradient Boosting在误诊控制方面表现更加稳定，而Logistic Regression则在保持较高Precision的同时获得了更高的Recall。

Recall分析

Recall指标反映了模型识别恶性肿瘤样本的能力，其计算公式为：

$$Recall = \frac{TP}{TP + FN} \quad (5.1)$$

其中：

- TP 表示正确识别的恶性样本数量；
- FN 表示被漏诊的恶性样本数量。

实验结果显示：

$$Recall_{GB} = 90.48 \quad (5.2)$$

$$Recall_{LR} = 92.86 \quad (5.3)$$

说明Logistic Regression能够识别出更多恶性患者，从而减少漏诊情况。

在医学诊断场景中，漏诊恶性肿瘤可能导致患者错过最佳治疗时机，因此Recall通常比Precision更加重要。因此从医疗应用角度来看，Logistic Regression在本实验中的实际应用价值略高于Gradient Boosting。

综合分析可以发现，两种模型均取得了96.49%的分类准确率，表现出较高的分类能力。其中，Gradient Boosting具有更高的Precision，能够有效降低误诊风险；而Logistic Regression具有更高的Recall，能够识别更多恶性肿瘤样本，减少漏诊情况。

因此，在实际医疗诊断场景中，如果更加关注恶性肿瘤的检出率，应优先考虑Recall较高的Logistic Regression；如果更加关注误诊控制，则Gradient Boosting更具优势。总体而言，两种模型均能够较好地完成乳腺癌分类任务，但在不同应用需求下各有优势。

5.1.6 结果总结

综上所述，Gradient Boosting模型在乳腺癌诊断数据集上取得了96.49%的分类准确率和95.00%的F1-score，表现出较高的分类精度和较强的泛化能力。模型不仅能够准确识别绝大多数恶性与良性样本，而且能够自动发现影响分类结果的重要医学特征。

在医疗诊断场景中，召回率（Recall）通常比准确率更重要，因为漏诊恶性肿瘤的代价远高于误诊良性肿瘤。本实验中模型召回率达到90.48%，说明其能够识别绝大多数恶性病例，但仍存在4例漏诊情况，后续可通过调整分类阈值、增加弱学习器数量或采用XGBoost等改进算法进一步提高恶性样本的检出率。

5.2 回归问题实验

采用Gradient Boosting算法对California Housing数据集进行房价预测实验。该数据集共包含20640个样本和8个特征变量，目标变量为房屋价格中位数。实验过程中未发现缺失值，因此无需进行缺失值填补处理。按照80%和20%的比例划分训练集和测试集，最终得到16512个训练样本和4128个测试样本。

5.2.1 数据集基本情况分析

California Housing数据集的目标变量统计信息如表8所示。

Table 8: 目标变量统计信息	
统计指标	数值
样本数量 (Count)	20640
均值 (Mean)	2.0686
标准差 (Std)	1.1540
最小值 (Min)	0.1500
第一四分位数 (25%)	1.1960
中位数 (50%)	1.7970
第三四分位数 (75%)	2.6473
最大值 (Max)	5.0000

由表8可知，房屋价格中位数分布范围较广，最小值约为0.15，最大值约为5.00，说明数据集中不同地区房价差异较大，具有较强的非线性特征，因此适合采用Gradient Boosting等非线性模型进行建模。

5.2.2 回归性能分析

Gradient Boosting模型在测试集上的回归性能如表9所示。

Table 9: Gradient Boosting回归结果	
评价指标	结果
MSE	0.2615
RMSE	0.5114
MAE	0.3484
R^2	0.8004

从表9可以看出，Gradient Boosting模型取得了较好的预测效果。其中，均方误差 (MSE) 为0.2615，说明模型整体预测误差较小;均方根误差 (RMSE) 为0.5114，表明模型预测值与真实值之间的平均偏差约为0.51个房价单位;平均绝对误差 (MAE) 为0.3484，进一步说明模型在大多数样本上的预测结果与真实值较为接近;决定系数 (R^2) 达到0.8004，说明模型能够解释约80.04%的房价变化信息，具有较好的拟合能力和泛化能力。

通常情况下，当 R^2 超过0.80时，说明模型已经能够较准确地刻画特征变量与目标变量之间的关系。因此，本实验结果表明Gradient Boosting能够有效完成房价预测任务。

5.2.3 特征重要性分析

Gradient Boosting模型能够自动评估各特征对预测结果的重要程度。实验得到的特征重要性排序如表10所示。

Table 10: 特征重要性排序

特征名称	Importance
MedInc	0.5874
AveOccup	0.1224
Longitude	0.1160
Latitude	0.1030
HouseAge	0.0359
AveRooms	0.0253
AveBedrms	0.0063
Population	0.0037

由表10可知，MedInc（家庭收入中位数）是影响房价预测最重要的因素，其重要性达到0.5874，占总体重要性的58%以上。这表明居民收入水平对房价具有决定性影响，收入越高的地区通常房价越高。

此外，AveOccup（平均入住人数）、Longitude（经度）以及Latitude（纬度）的重要性也较高，说明人口分布以及地理位置对房价具有显著影响。相比之下，Population（人口数量）和AveBedrms（平均卧室数）的重要性较低，说明这些因素对房价的直接影响相对较弱。

从整体来看，Gradient Boosting成功识别出了影响房价的关键因素，并且这些结果与房地产经济学中的基本规律相一致。

5.2.4 预测结果分析

为了观察模型预测效果，随机选取部分测试样本进行分析，如表11所示。

Table 11: 部分样本预测结果

真实值	预测值	误差	真实值	预测值	误差
0.4770	0.4317	0.0453	1.5870	1.6715	-0.0845
0.4580	1.0991	-0.6411	1.9820	2.2886	-0.3066
5.0000	4.6416	0.3584	1.5750	1.6459	-0.0709
2.1860	2.4303	-0.2443	3.4000	3.0386	0.3614
2.7800	2.3487	0.4313	4.4660	4.3428	0.1232

从表11可以发现，大多数样本的预测值与真实值较为接近。例如第10个样本真实值为4.4660，预测值为4.3428，两者误差仅为0.1232。但同时也存在个别误差较大的样本，例如第2个样本误差达到0.6411。这说明部分地区房价可能受到数据集中未包含的因素影响，如区域经济环境、教育资源以及交通条件等，从而导致预测误差增加。

总体来看，大多数样本误差均控制在合理范围内，说明Gradient Boosting具有较好的预测稳定性。

5.2.5 对比实验

为了进一步验证Gradient Boosting算法在回归任务中的性能，本文选取Linear Regression（线性回归）作为对比模型，在相同的数据集、训练集与测试集划分条件下进行实验。两种模型的回归性能对比如表12所示。

Table 12: Gradient Boosting与Linear Regression性能对比

模型	MSE	RMSE	MAE	R^2
Gradient Boosting	0.2615	0.5114	0.3484	0.8004
Linear Regression	0.5559	0.7456	0.5332	0.5758

由表12可以看出，Gradient Boosting在所有评价指标上均优于Linear Regression。

其中，Gradient Boosting的均方误差（MSE）为0.2615，而Linear Regression的MSE达到0.5559，前者仅为后者的47%左右，说明Gradient Boosting具有更高的预测精度。

在均方根误差（RMSE）方面，Gradient Boosting取得了0.5114的结果，明显低于Linear Regression的0.7456，表明Gradient Boosting的预测结果更加接近真实房价。

平均绝对误差（MAE）方面，Gradient Boosting的MAE为0.3484，而Linear Regression达到0.5332，说明Gradient Boosting在绝大多数样本上的预测偏差更小。

决定系数（ R^2 ）是衡量模型解释能力的重要指标。Gradient Boosting取得了0.8004的 R^2 值，说明模型能够解释约80.04%的房价变化；而Linear Regression仅达到0.5758，仅能解释57.58%的房价变化。因此，Gradient Boosting对房价变化规律的刻画能力明显优于Linear Regression。

评价指标可视化分析

为了更加直观地比较两种模型的性能，绘制评价指标对比柱状图，如图2所示。




Figure 2: 回归评价指标对比

从图2可以明显看出，Gradient Boosting在误差指标（MSE、RMSE、MAE）上均显著低于Linear Regression，而在决定系数 R^2 上则明显高于Linear Regression。

这说明Gradient Boosting能够更准确地学习房价与特征变量之间的复杂非线性关系，而Linear Regression由于仅能拟合线性关系，因此预测能力受到较大限制。

预测结果分析

为了比较两种模型对实际房价的拟合能力，绘制真实值与预测值对比曲线，如图3所示。




Figure 3: 真实值与预测值对比

由图3可以发现，Gradient Boosting预测曲线与真实房价曲线具有更高的一致性，在大部分样本点上能够较好地跟踪真实房价变化趋势。

相比之下，Linear Regression预测曲线偏离真实值的情况更加明显，尤其是在房价较高或较低的区域，预测误差进一步增大。这表明线性回归难以有效描述房价数据中存在的复杂非线性特征。

预测误差分析

为了进一步分析两种模型的误差分布情况，绘制预测误差对比曲线，如图4所示。




Figure 4: 预测误差对比

图4中虚线表示零误差位置。当误差越接近零时，说明模型预测越准确。

从图中可以看出，Gradient Boosting的误差波动范围明显小于Linear Regression，大部分误差集中在零附近，说明模型预测结果更加稳定。

而Linear Regression存在多个较大的正误差和负误差，其误差波动范围明显更宽，部分样本误差甚至超过2个房价单位。这进一步说明Linear Regression难以准确拟合房价数据中的复杂变化规律。

特征重要性分析

Gradient Boosting模型计算得到的特征重要性如表13所示。

Table 13: Gradient Boosting特征重要性			
特征名称	Importance	特征名称	Importance
MedInc	0.5874	HouseAge	0.0359
AveOccup	0.1224	AveRooms	0.0253
Longitude	0.1160	AveBedrms	0.0063
Latitude	0.1030	Population	0.0037

由表13可以看出，MedInc（家庭收入中位数）是影响房价预测最重要的因素，其重要性达到58.74%。此外，AveOccup、Longitude和Latitude的重要性也较高，说明居民收入水平以及地理位置是决定房价的重要因素。

这些结果与房地产市场的一般规律相一致，进一步验证了Gradient Boosting模型具有较好的解释能力。

综合分析可知，Gradient Boosting在California Housing数据集上的表现明显优于Linear Regression。在误差指标方面，Gradient Boosting的MSE、RMSE和MAE均显著低于Linear Regression；在模型解释能力方面，其 R^2 达到0.8004，远高于Linear Regression的0.5758。

实验结果表明，California Housing数据集具有明显的非线性特征，而Gradient Boosting通过集成多棵决策树能够有效学习复杂的非线性关系，因此具有更强的预测能力和更好的泛化性能。相比之下，Linear Regression仅能建立线性映射关系，因此在房价预测任务中的表现相对较弱。

因此，在结构化房价预测等回归问题中，Gradient Boosting具有更高的应用价值和实际推广意义。

5.2.6 结果总结

综上所述，Gradient Boosting模型在California Housing数据集上取得了较好的回归性能，其中决定系数达到0.8004，均方根误差为0.5114。模型不仅能够较准确地预测房屋价格，而且能够自动发现影响房价的重要因素。实验结果表明，Gradient Boosting在结构化数据回归问题中具有较强的建模能力和良好的应用价值。

6 总结与展望

6.1 研究总结

本文围绕Gradient Boosting算法展开研究，系统分析了其基本原理、求解过程以及在分类与回归问题中的应用方法。首先，从集成学习的角度出发，对Gradient Boosting算法的理论基础进行了阐述，推导了目标函数、模型初始化、负梯度计算以及模型迭代更新等关键步骤，并说明了其通过逐步拟合损失函数负梯度实现模型优化的核心思想。

为了验证Gradient Boosting算法的实际应用效果，本文分别选取乳腺癌诊断数据集（Breast Cancer Wisconsin Diagnostic Dataset）和加州房价数据集（California Housing Dataset）开展分类与回归实验研究。

在分类实验中，利用Gradient Boosting模型对乳腺癌良恶性进行识别。实验结果表明，模型在测试集上取得了96.49%的分类准确率、100%的精确率以及90.48%的召回率，能够准确识别绝大多数肿瘤样本。同时，通过特征重要性分析发现，细胞核周长、凹陷程度以及纹理等特征对分类结果具有重要影响，所得结论与医学领域已有研究结果具有较好的一致性。

在回归实验中，利用Gradient Boosting模型对加州房价进行预测。实验结果显示，模型取得了0.2615的均方误差（MSE）、0.5114的均方根误差（RMSE）、0.3484的平均绝对误差（MAE）以及0.8004的决定系数（ R^2 ）。结果表明，Gradient Boosting能够较好地学习房价与区域特征之间复杂的非线性关系，具有较强的预测能力和泛化性能。

为了进一步验证模型性能，本文设计了两组对比实验。在分类任务中，将Gradient Boosting与Logistic Regression进行比较；在回归任务中，将Gradient Boosting与Linear Regression进行比较。实验结果表明：

- 在分类任务中，两种模型均取得较高准确率，但Gradient Boosting具有更高的Precision，而Logistic Regression具有更高的Recall；
- 在回归任务中，Gradient Boosting在MSE、RMSE、MAE以及 R^2 等指标上均明显优于Linear Regression；
- Gradient Boosting能够有效处理复杂非线性关系，在结构化数据分析任务中表现出较强的建模能力。

综合理论分析与实验结果可以得出结论：Gradient Boosting作为一种典型的集成学习算法，具有较高的预测精度、良好的泛化能力以及较强的特征表达能力，在分类与回归问题中均展现出优异性能，是解决实际机器学习问题的重要工具。

6.2 研究展望

虽然Gradient Boosting在本文实验中取得了较好的效果，但仍有进一步优化和研究的空间。首先，本文主要研究了传统Gradient Boosting算法，而XGBoost、LightGBM和CatBoost等改进模型在训练效率和预测性能方面表现更优。未来可进一步比较这些算法的性能差异及其适用场景。其次，本文所采用的数据集规模相对有限，未来可在更大规模、更高维度的数据集上开展实验，并结合交叉验证、超参数优化和特征选择等方法进一步提升模型性能和泛化能力。此外，集成学习与深度学习的融合已成为机器学习的重要研究方向。未来可探索Gradient Boosting与神经网络结合的方法，发挥两类模型在特征学习和预测能力方面的优势。

总体而言，Gradient Boosting及其改进算法在医疗诊断、金融风控、房价预测等领域仍具有广阔的应用前景。随着数据规模和计算能力的不断提升，其将在更多复杂实际问题中发挥重要作用。

7 参考文献

- [1] Zhang Z, Zhao Y, Chen X, et al. Unbiased Gradient Boosting Decision Tree with Categorical Feature Encoding[J]. Proceedings of the International Joint Conference on Artificial Intelligence (IJCAI), 2023.
- [2] Ahn J M, Kim J, Kim H, et al. Ensemble Machine Learning of Gradient Boosting (XGBoost, LightGBM, CatBoost) and Attention-Based CNN-LSTM for Harmful Algal Blooms Forecasting[J]. Heliyon, 2023, 9(11): e21335.
- [3] Bentéjac C, Csörgő A, Martínez-Muñoz G. A Comparative Analysis of Gradient Boosting Algorithms[J]. Artificial Intelligence Review, 2021, 54(3): 1937–1967.
- [4] Dorogush A V, Ershov V, Gulin A. CatBoost: Gradient Boosting with Categorical Features Support[J]. Journal of Machine Learning Research, 2020, 21(1): 1–45.
- [5] ApX Machine Learning. XGBoost vs. LightGBM vs. CatBoost: A Comparison[EB/OL]. 2020. :contentReference[oaicite:0]index=0
- [6] Shi Y, Li J, Li Z. Gradient Boosting With Piece-Wise Linear Regression Trees[J]. IEEE Transactions on Knowledge and Data Engineering, 2019.
- [7] Prokhorenkova L, Gusev G, Vorobev A, et al. CatBoost: Unbiased Boosting with Categorical Features[J]. Advances in Neural Information Processing Systems, 2018, 31. :contentReference[oaicite:1]index=1

- [8] Ke G, Meng Q, Finley T, et al. LightGBM: A Highly Efficient Gradient Boosting Decision Tree[J]. *Advances in Neural Information Processing Systems*, 2017, 30. :contentReference[oaicite:2]index=2
- [9] Chen T, Guestrin C. XGBoost: A Scalable Tree Boosting System[C]. *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, 2016: 785–794. :contentReference[oaicite:3]index=3
- [10] James G, Witten D, Hastie T, Tibshirani R. *An Introduction to Statistical Learning*[M]. New York: Springer, 2013.
- [11] Hastie T, Tibshirani R, Friedman J. *The Elements of Statistical Learning*[M]. 2nd Edition. New York: Springer, 2009.
- [12] Wu X, Kumar V, Quinlan J R, et al. Top 10 Algorithms in Data Mining[J]. *Knowledge and Information Systems*, 2008, 14(1): 1–37. :contentReference[oaicite:4]index=4
- [13] Lichman M. *UCI Machine Learning Repository*[DB/OL]. University of California, Irvine, 2013.
- [14] Pedregosa F, Varoquaux G, Gramfort A, et al. Scikit-learn: Machine Learning in Python[J]. *Journal of Machine Learning Research*, 2011, 12: 2825–2830.
- [15] Natekin A, Knoll A. Gradient Boosting Machines, A Tutorial[J]. *Frontiers in Neuro-robotics*, 2013, 7: 21.
- [16] Boehmke B, Greenwell B. *Hands-On Machine Learning with R*[M]. Chapman and Hall/CRC, 2019. :contentReference[oaicite:5]index=5
- [17] Breiman L. Random Forests[J]. *Machine Learning*, 2001, 45(1): 5–32.
- [18] Friedman J H. Greedy Function Approximation: A Gradient Boosting Machine[J]. *The Annals of Statistics*, 2001, 29(5): 1189–1232. :contentReference[oaicite:6]index=6
- [19] Breiman L. Statistical Modeling: The Two Cultures[J]. *Statistical Science*, 2001, 16(3): 199–231.
- [20] Friedman J H. Stochastic Gradient Boosting[J]. *Computational Statistics & Data Analysis*, 2002, 38(4): 367–378. :contentReference[oaicite:7]index=7

- [21] Mason L, Baxter J, Bartlett P, et al. Boosting Algorithms as Gradient Descent[J]. Advances in Neural Information Processing Systems, 2000.
- [22] Breiman L. Bagging Predictors[J]. Machine Learning, 1996, 24(2): 123–140.
- [23] Quinlan J R. C4.5: Programs for Machine Learning[M]. San Mateo: Morgan Kaufmann, 1993.
- [24] Freund Y, Schapire R E. A Decision-Theoretic Generalization of On-Line Learning and an Application to Boosting[J]. Journal of Computer and System Sciences, 1997, 55(1): 119–139.
- [25] Wolberg W H, Mangasarian O L. Multisurface Method of Pattern Separation for Medical Diagnosis Applied to Breast Cytology[J]. Proceedings of the National Academy of Sciences, 1990, 87(23): 9193–9196.